



Instituto Tecnológico  
de Buenos Aires

# TRABAJO PRÁCTICO N°2

## CUADRADOS MÍNIMOS

93.54 Métodos Numéricos

Grupo N°4

Legajo N°	Nombre
61428	Kevin Amiel Wahle
61430	Francisco Basili
61431	Nicolás Bustelo

21/04/2022

## Índice

<b>1. Introducción</b>	<b>2</b>
<b>2. Función <i>leastsq</i> (<i>A,b</i>)</b>	<b>2</b>
<b>3. Funciones Utilizadas</b>	<b>2</b>
3.1. <i>Cholesky</i> ( <i>A, ncols</i> ) . . . . .	2
3.2. Resolución de sistemas triangulares . . . . .	2
3.3. Funciones auxiliares . . . . .	2
<b>4. TestBench</b>	<b>2</b>
<b>5. Aplicación práctica de cuadrados mínimos</b>	<b>3</b>
<b>6. Anexo</b>	<b>4</b>
6.1. Código completo en Python . . . . .	4

## 1. Introducción

El objetivo de este informe es presentar y explicar el funcionamiento de un programa realizado en *Python*, el cual consiste en resolver el problema de cuadrados mínimos lineal, utilizando la descomposición de Cholesky. A su vez, también se escribió una función que ajustase los datos de un archivo a una curva dada. El código se encuentra adjunto en la entrega del TP, y también se lo puede ver en el Anexo (sección 6).

## 2. Función *leastsq* (*A*,*b*)

La función *leastsq*(*A*,*b*) resuelve el sistema de ecuaciones  $A\vec{x} = \vec{b}$  utilizando la descomposición Cholesky, y luego el método de ecuaciones normales.

Para ello, dado  $A \in \mathbb{R}^{n \times m}$ , se obtuvo  $A' = A^T A \in \mathbb{R}^{n \times n}$ . Se corroboró que esta matriz  $A'$  cumpliera con las hipótesis necesarias para aplicar la descomposición Cholesky: se verificó que la matriz fuera definida positiva y que fuera simétrica.

Luego, una vez obtenida la  $G$  al usar la descomposición Cholesky (que se encuentra explicada en la sección 3.1) para  $A'$ , se procedió a resolver el sistema  $GG^T \vec{x} = A^T \vec{b}$ . Para ello, se resolvieron los sistemas  $G\vec{y} = A^T \vec{b}$  y  $\vec{y} = G^T \vec{x}$ .

Sabiendo que tanto  $G$  como  $G^T$  son matrices triangulares conocidas, con las funciones *LsolverLower*(*mat*, *B*) y *LsolverUpper*(*mat*, *B*) (que se encuentran explicadas en la sección 3.2), se resolvieron los sistemas triangulares, obteniendo primero  $\vec{y}$  y, con ella,  $\vec{x}$ .

## 3. Funciones Utilizadas

### 3.1. *Cholesky*(*A*, *ncols*)

La función *Cholesky*(*A*, *ncols*) calcula la matriz  $G$  triangular inferior tal que  $GG^T = A^T A$ . Esta función no verifica que la matriz sea definida positiva, ya que esta verificación se realiza en la función *leastsq* (*A*,*b*).

### 3.2. Resolución de sistemas triangulares

Las funciones *LsolverLower*(*mat*, *B*) y *LsolverUpper*(*mat*, *B*) resuelven sistemas lineales de ecuaciones triangulares. Para la primera de ellas *mat* debe ser una matriz triangular inferior, mientras que para la segunda debe ser una matriz triangular superior. Una vez resuelto el sistema retornan el vector solución.

### 3.3. Funciones auxiliares

La función *transpuesta*(*mat*, *nrows*, *ncols*) toma una matriz de cualquier dimensión y retorna su matriz transpuesta pasando elemento a elemento.

La función *esSimetrica*(*mat*, *ncols*) verifica que *mat* sea simétrica recorriendo únicamente el triángulo superior de la misma.

La función *autovalores*(*mat*) calcula todos los autovalores de la matriz *mat*. Luego, sabiendo si la matriz es simétrica, se analizan estos autovalores para determinar si la matriz es definida positiva.

## 4. TestBench

El objetivo del TestBench es comprobar el correcto funcionamiento de la función *leastsq*(*b*). Para ello, se la ejecutó con diferentes matrices, algunas cuyo producto con su transpuesta no es una matriz

definida positiva o no es una matriz simétrica. Para comparar con los resultados de nuestra función se utilizó la función *lstsq()* del paquete *numpy.linalg* que sabemos que brinda resultados fiables.

## 5. Aplicación práctica de cuadrados mínimos

Se utilizó la función *leastsq()* para encontrar la mejor aproximación a los  $N = 441.000$  datos, que se encontraban en un archivo "sound.txt" a la función de la ecuación (1). En dicho archivo interpretamos que la primera columna como valores  $y$  y la segunda columna como  $t$ .

$$y(t) = \sum_{k=1}^3 [a_k \cdot \cos(1000 \cdot k \cdot \pi \cdot t) + b_k \cdot \sin(1000 \cdot k \cdot \pi \cdot t)] \quad (1)$$

Interpretamos los datos para lograr representarlos como un sistema lineal de matrices  $A^T \cdot \vec{x} = \vec{b}$ . Donde  $\vec{b}$  es un vector con todos los valores de  $y$ , el vector  $\vec{x} = [a_1, a_2, a_3, b_1, b_2, b_3]^T$  y por último en la matriz  $A$  se encontraban, dispuestos por columna, los valores obtenidos de evaluar cada una de las funciones para un dado  $t_n$ .

$$A = \begin{bmatrix} \cos(1000 \cdot \pi \cdot t_0) & \dots & \cos(1000 \cdot \pi \cdot t_N) \\ \cos(2000 \cdot \pi \cdot t_0) & \dots & \cos(2000 \cdot \pi \cdot t_N) \\ \cos(3000 \cdot \pi \cdot t_0) & \dots & \cos(3000 \cdot \pi \cdot t_N) \\ \sin(1000 \cdot \pi \cdot t_0) & \dots & \sin(1000 \cdot \pi \cdot t_N) \\ \sin(2000 \cdot \pi \cdot t_0) & \dots & \sin(2000 \cdot \pi \cdot t_N) \\ \sin(3000 \cdot \pi \cdot t_0) & \dots & \sin(3000 \cdot \pi \cdot t_N) \end{bmatrix}$$

Gracias la función *leastsq* se obtuvieron los valores de  $a_k$  y  $b_k$  y se obtuvo un arreglo de errores de ajuste. Para ver la similitud entre los valores de  $y(t)$  calculados con la ecuación (1) y los del archivo, se las graficó (ver figura 1) y se puede apreciar en la siguiente figura la gran similitud.




Figura 1: Comparación de los valores con la curva aproximada.

## 6. Anexo

### 6.1. Código completo en Python

```

1 # -----
2 # @file      +leastchol.py+
3 # @brief     +Cuadrados mínimos+
4 # @author    +Grupo 4+
5 # -----
6
7 # -----
8 # LIBRARIES
9 # -----
10 import numpy as np
11 import pandas as pd
12 import matplotlib.pyplot as plt
13 import math as mt
14
15 # -----
16 # FUNCTION DEF
17 # -----
18 # Resolución de sistemas de ecuaciones con la descomposición Cholesky
19 def leastsq(A, b):
20     N = len(A)      #Numero de filas
21     Nc = len(A[0])  #Numero de columnas
22
23     At = transpuesta(A, N, Nc)
24
25     if (autovalores(At@A).min() <= 0 or not esSimetrica(At@A, Nc)):
26         print("La matriz no es definida positiva")
27         return None
28
29     X = np.zeros(Nc)
30
31     G = Cholesky(At@A, Nc)
32     Gt = transpuesta(G, Nc, Nc)
33
34     Y = LsolverLower(G, At@b)
35     X = LsolverUpper(Gt, Y)
36     return X
37
38 # Calculo de la descomposición Cholesky
39 def Cholesky(A, N):
40     G = np.zeros((N,N)) # G es la matriz de Cholesky
41     for i in range(N):
42         for j in range(i+1):
43             suma = 0
44             for k in range(j):
45                 suma += G[i][k]*G[j][k] # suma es la suma de los elementos de la fila
46             anterior
47             if (i == j):
48                 G[i][i] = np.sqrt(A[i][i] - suma) # G[i][i] es el elemento diagonal de la
49             matriz de Cholesky
50             else:
51                 G[i][j] = (A[i][j] - suma)/G[j][j] # G[i][j] es el elemento de la matriz
52             de Cholesky
53     return G # Retornamos la matriz de Cholesky
54
55 #Resuelve el cálculo de un sistema lineal con una matriz triangular inferior
56 def LsolverLower(Lm, B):
57     n = len(B)
58     Y = np.zeros(n)
59     for i in range(n):
60         suma = 0
61         for j in range(i):
62             suma += Lm[i][j]*Y[j]
63         Y[i] = (B[i] - suma)/Lm[i][i]
64     return Y
65
66 #Resuelve el cálculo de un sistema lineal con una matriz triangular superior
67 def LsolverUpper(Um, Y):
68     n = len(Y)

```

```

66     X = np.zeros(n)
67     for i in range(n-1,-1,-1):
68         suma = 0
69         for j in range(n-1,i-1,-1):
70             suma += Um[i][j]*X[j]
71             X[i] = (Y[i] - suma)/Um[i][i]
72     return X
73
74 # Calculo de autovalores de la matriz A
75 def autovalores(A):
76     aVa = np.linalg.eigvals(A)
77     return aVa
78
79 # Calculo de la transpuesta
80 def transpuesta(mat, N, Nc):
81     trans = np.empty((Nc, N))
82     for i in range(Nc):
83         for j in range(N):
84             trans[i][j] = mat[j][i]
85     return trans
86
87 # True si es simetrica, False sino
88 def esSimetrica(mat, N):
89     for i in range(N):
90         for j in range(i,N):
91             if (mat[i][j] != mat[j][i]):
92                 return False
93     return True
94
95
96 # -----
97 # TEST
98 # -----
99 def comp(A, b):
100     At = transpuesta(A, len(A), len(A[0]))
101     print("\n")
102     # Método del grupo 4 para resolución de sistemas de ecuaciones
103     X = leastsq(A, b)
104     print("Resultado calculado: ",X)
105
106     # Método de numpy para resolución de sistemas de ecuaciones
107     X1= np.linalg.lstsq(A, b, rcond=None)[0]
108     print("Resultado de linalg: ", X1)
109
110     if (X is None): # Si no es definida positiva
111         return 1    # No se puede resolver por Cholesky
112
113     if np.allclose(X, X1):    # Comparamos las dos matrices
114         print("Prueba exitosa")
115         return 1
116     else:
117         print("Prueba fallida")
118         return 0
119
120
121 def test():
122     pOk=0; ptotales=0
123
124     A = np.array([[ -1, -1], [1, 0]])
125     b = np.zeros((2,1)); b=[0,1]
126     pOk += comp(A, b)
127     ptotales+=1
128
129     A = np.array([[2, -1], [-1, 2]])
130     b = np.zeros((2,1)); b=[3,8]
131     pOk += comp(A, b)
132     ptotales+=1
133
134     A = np.array([[0, 1], [0, 1]])    # Matriz no definida positiva
135     b = np.zeros((2,1)); b=[0,0]
136     pOk += comp(A, b)
137     ptotales+=1

```

```

138
139     A = np.array([[0, -0.45], [10000, 0]])
140     b = np.zeros((2,1)); b=[0.003, -87]
141     p0k += comp(A, b)
142     ptotales+=1
143
144     A = np.array([[2, -1, 0], [-1, 2, -1], [0, -1, 2]])
145     b = np.zeros((3,1)); b=[1,2,3]
146     p0k += comp(A, b)
147     ptotales+=1
148
149     A = np.array([[-8, 1.1, 0], [-1, 3, 1], [0, 7, 5]])
150     b = np.zeros((3,1)); b=[15,8,3.2]
151     p0k += comp(A, b)
152     ptotales+=1
153
154     print(f"Se superaron: {p0k} de {ptotales} pruebas totales")
155
156
157 # -----
158 # Aplicación práctica de cuadrados mínimos
159 # -----
160 def sonido():
161     #Cargamos y mostramos los datos del TP
162     df = pd.read_csv('sound.txt', header=None, names=['ti', 'yi'], dtype={'ti': np.float64, 'yi': np.float64}, sep=' ')
163
164     ti = np.array(df['ti'].tolist())
165     yi = np.array(df['yi'].tolist())
166
167
168     A = [np.cos(1000*np.pi*ti), np.cos(2000*np.pi*ti), np.cos(3000*np.pi*ti), np.sin(1000*
169 np.pi*ti), np.sin(2000*np.pi*ti), np.sin(3000*np.pi*ti)]
170     At = np.transpose(A)
171     b = np.asarray(yi)
172
173     Xvect = leastsq(At, b) # Se carga la transpuesta de A y se resuelve el sistema de
174 ecuaciones
175
176     ycalc= At@Xvect #Calculamos los valores de y a partir de las constantes calculadas
177
178     error = np.subtract(yi, ycalc) #Calculamos el error
179
180     #Graficamos los datos para ver la similitud
181     plt.plot(ti, yi, label="Teórica")
182     plt.plot(ti, ycalc, label="Aproximada")
183     plt.get_current_fig_manager().window.showMaximized()
184     plt.tight_layout()
185     plt.legend()
186     plt.show()
187
188     return Xvect, error

```